

Optimización de Costos y Matriz de Decisión de Modelos

Ecosistema de Automatización IA — Venta de e-books y atención de consultas

Cinthia Ávalos · Proyecto Integrador Final · IA Automation

1. Contexto y justificación de las herramientas elegidas

Antes de entrar en la matriz de costos, es importante aclarar por qué el sistema implementado usa Gemini como motor de IA y Gmail como canal de comunicación, en lugar de OpenAI (GPT) o Anthropic (Claude), que son las opciones que se evalúan..

Motor de IA: Al momento de construir este proyecto estoy en licencia por maternidad y sin ingresos, por lo que no cuento con presupuesto disponible para cargar crédito en la API de OpenAI o Anthropic. Elegí Gemini porque su capa gratuita de Google AI Studio permite ejecutar el agente de IA del flujo (RAG sobre el manual en PDF) sin costo, algo que ni OpenAI ni Anthropic ofrecen hoy con ese nivel de uso. Esta decisión responde a una restricción real y puntual de recursos, no a que Gemini sea la opción recomendada en un escenario de producción con presupuesto disponible — por eso en este documento sí se compara contra GPT-4o-mini y Claude Haiku, como pide la consigna, para justificar cuál convendría en cada tarea si el proyecto se llevara a la vida real.

Canal de salida: Se usó Gmail para todas las notificaciones (cliente y vendedor/HITL) en lugar de Slack o WhatsApp API. Es el canal que efectivamente usaría en mi negocio real: mis clientas me escriben y esperan respuestas por email, no manejo un workspace de Slack propio, y la API de WhatsApp Business requiere aprobación de plantillas y tiene costo por conversación iniciada. Gmail, en cambio, no tiene costo adicional en la cuenta que ya uso y es el canal con el que mis clientas están familiarizadas.

2. Matriz de decisión: qué modelo usar por tarea

El flujo tiene varias tareas que podrían "tentar" a usar IA en todas partes, pero no todas la necesitan. La primera optimización de costos, antes de elegir un modelo, es no llamar a un LLM cuando no hace falta:

Tarea del flujo	¿Necesita IA?	Motor recomendado	Por qué
Clasificar el libro elegido (switch)	No	Lógica de reglas (if/switch)	Es una comparación exacta de texto contra 4 opciones fijas del formulario. Un LLM sería más lento, menos confiable (podría alucinar una categoría) y con costo innecesario.
Emails de datos bancarios, confirmación de venta y aviso de comprobante	No	Plantillas Gmail con variables dinámicas	El contenido es siempre el mismo texto con datos del cliente insertados. No requiere generación de lenguaje natural variable.
Responder consultas abiertas del cliente (RAG sobre el manual)	Si	Modelo económico de lectura media (Gemini Flash-Lite / GPT-4o-mini / Claude Haiku)	Es la única tarea con lenguaje natural real: hay que interpretar una pregunta libre y responder solo con la información del manual. El manual es acotado (un PDF de recetario), no es "lectura densa" de cientos de páginas, así que un modelo de nivel Haiku/mini alcanza y sobra.

Tarea del flujo	¿Necesita IA?	Motor recomendado	Por qué
Procesamiento en lote de consultas históricas (si se acumularan cientos)	Sí (a futuro)	API de Batches del proveedor elegido	Hoy el volumen es bajo y cada consulta se responde casi en tiempo real. Si el negocio creciera y se quisiera reprocesar o auditar cientos de consultas fuera de horario, el batch processing da ~50% de descuento porque no requiere respuesta inmediata.

Tabla 1 — Qué tareas del flujo realmente requieren un modelo de IA.

Conclusión de la matriz: de las 4 tareas del ecosistema, solo una necesita un LLM. Esa es, en sí misma, la decisión de optimización de costos más importante del proyecto — evita pagar (o consumir cuota gratuita) por generación de texto en tareas 100% determinísticas.

3. Cuadro comparativo de costos — tarea de consultas (RAG)

Para la única tarea que sí usa IA, se compara el costo real de tres motores posibles, estimando una consulta típica de ~4.000 tokens de entrada (manual del recetario + prompt + pregunta del cliente) y ~200 tokens de salida (la respuesta). Precios de lista públicos, vigentes a septiembre de 2026:

Modelo	Input \$/1M tok	Output \$/1M tok	Costo / consulta	Costo / mes (200 consultas)
Gemini 3.1 Flash-Lite (usado en el proyecto)	\$0.25	\$1.50	≈ \$0.0013	≈ \$0.26
GPT-4o-mini	\$0.15	\$0.60	≈ \$0.0007	≈ \$0.14
Claude Haiku 4.5	\$0.25	\$1.25	≈ \$0.0013	≈ \$0.25

Tabla 2 — Costo estimado de la tarea de consultas con distintos motores, a un volumen realista de emprendimiento chico.

A este volumen (decenas a un par de cientos de consultas por mes), la diferencia entre los tres motores es de centavos: no es donde se juega el ahorro. Lo que sí cambia el costo en un orden de magnitud es elegir la categoría de modelo (económico vs. de última generación), no el proveedor:

Categoría	Ejemplo	Costo / consulta (4K in / 200 out)	Veces más caro que el nivel económico
Económico / lite (el usado acá)	Gemini Flash-Lite, GPT-4o-mini, Claude Haiku	≈ \$0.001	1x
Intermedio	Gemini 2.5 Flash, GPT-4.1	≈ \$0.003 – \$0.01	3x – 10x
Frontera / reasoning	Claude Opus 4.6, GPT-5, Gemini 3.1 Pro	≈ \$0.02 – \$0.05	15x – 40x

Tabla 3 — Impacto de elegir un modelo económico en vez de un modelo de frontera para esta tarea puntual.

4. Ahorro estimado

- Ahorro por no usar IA donde no hace falta: si se hubiera resuelto todo el flujo (switch + emails + consultas) con un LLM, el costo mensual sería el mismo orden de magnitud solo en la parte de consultas, pero se sumarían

decenas de llamadas extra por cada venta (clasificar, redactar cada email, etc.). Al resolver esas 3 tareas con reglas y plantillas, ese costo es directamente \$0.

- Ahorro por elegir un modelo económico y no uno de frontera: usar Gemini Flash-Lite (o GPT-4o-mini / Claude Haiku) en vez de un modelo tipo Opus/GPT-5/Gemini Pro representa un ahorro de entre 90% y 97% por consulta, sin pérdida de calidad relevante, porque la tarea (responder sobre un manual acotado) no requiere razonamiento de frontera.
- Ahorro por usar la capa gratuita de Gemini durante el desarrollo: al día de hoy el volumen de consultas del proyecto entra dentro de la cuota gratuita diaria que da Google AI Studio, por lo que el costo real de operar el agente de IA durante esta etapa fue \$0. Es la razón concreta por la que se pudo construir y probar el flujo completo sin presupuesto disponible.
- Proyección a futuro: si el negocio creciera a un volumen alto de consultas (cientos por día) y se pudiera tolerar demora en la respuesta, migrar ese procesamiento a la API de Batches del proveedor elegido sumaría un ~50% adicional de ahorro sobre el costo por token ya económico.

5. Conclusión

La estrategia de costos del proyecto tiene dos capas: primero, minimizar cuántas veces se llama a un modelo de IA (solo 1 de 4 tareas lo necesita); segundo, dentro de esa única tarea, usar el modelo económico que alcanza para la complejidad real del trabajo (lectura de un manual acotado), en vez de un modelo de frontera. Gemini Flash-Lite fue la opción elegida por una restricción de presupuesto puntual y real durante la licencia por maternidad, pero como muestra la comparación, el costo hubiese sido igual de bajo con GPT-4o-mini o Claude Haiku — la decisión de diseño que realmente ahorra dinero es la de no sobre-dimensionar el modelo para la tarea, más allá de qué proveedor se use.